Q 酱的概统笔记 v2.2

陈联宇 PB24071436

$\because \quad \therefore \quad \sim \quad \otimes$

本概统笔记由 23 级物理学院于洪飞学长的 Yu的概统笔记 扩充而来, 进行重排版和适当删改. 同时感谢 q 酱[1]在撰写此笔记过程中的巨大贡献.



初等概率论

科大的*概率论与数理统计*这门课程中的概率论部分不依赖于 Kolmogorov 公理和测度论, 无需严格的数学, 仍属于初等概率论的范畴. 对于严格的分析语言感兴趣的同学可以自行阅读数学系的概率论教材.

1 古典模型

常用原理有: 加法原理, 乘法原理. 注意下面的 $0!=1$.

1.1 常规模型

从含有 n 个元素的盒子中:

- 有放回, 可重复排列: n^r;
- 无放回, 不重复排列: $P_n^r=\dfrac{n!}{(n-r)!}$ (排列数). 特别地, 当 $r=n$ 时称为全排列;
- 不放回地选取 r 个元素的组合有 $C_n^r=\dfrac{n!}{r!(n-r)!}$ 种 (组合数);
- 有放回地选取 r 个元素的组合有 C_{n+r-1}^r 种 (重复组合数).

1.2 盒子模型

把 r 个球放到不同编号的 n 个盒子中:

球	盒子	容量	公式	名称
可辨	可辨	无限制	n^r	有放回排列 / 函数个数
可辨	可辨	每盒 ≤ 1	A_n^r	无放回排列 $(r \leq n)$
不可辨	可辨	无限制	C_{n+r-1}^r	重复组合
不可辨	可辨	每盒 ≤ 1	C_n^r	普通组合 $(r \leq n)$

1.3 多组组合

把 n 个不同的元素分为有序的 k 个部分, 并且要求第 i 部分有 r_i 个元素, 不同的分法个数为 $\dfrac{n!}{r_1!r_2!\dots r_k!}$ (多项式系数).

1.4 二项式定理

根据上节可知:

$$(x_1 + \cdots + x_k)^n = \sum_{\sum r_i = n,\, r_i \geq 0} \frac{n!}{r_1! \cdots r_k!} x_1^{r_1} \cdots x_k^{r_k}$$

---

2 概率的性质

1. $P(\varnothing) = 0$;
2. 有限可加性:

$$P\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i=1}^{n} P(A_i), \quad \text{when } A_i \cap A_j = \varnothing \ (i \neq j)$$

3. $P(\bar{A}) = 1 - P(A)$, 其中 $\bar{A} = A^c = \Omega \setminus A$;
4. 容斥原理:

$$P\left(\bigcup_{k=1}^{n} A_k\right) = \sum_{m=1}^{n} (-1)^{m-1} \sum_{1 \leqslant i_1 < \cdots < i_m \leqslant n} P(A_{i_1} \cap \cdots \cap A_{i_m})$$

5. 次可加性:

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) \leqslant \sum_{n=1}^{\infty} P(A_n)$$

6. 连续性:
   - 下连续性: 若 $A_1 \subseteq A_2 \subseteq \cdots$, 则:

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} P(A_n)$$

   - 上连续性: 若 $A_1 \supseteq A_2 \supseteq \cdots$, 则:

$$P\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} P(A_n)$$

---

3 条件概率

3.1 基本性质

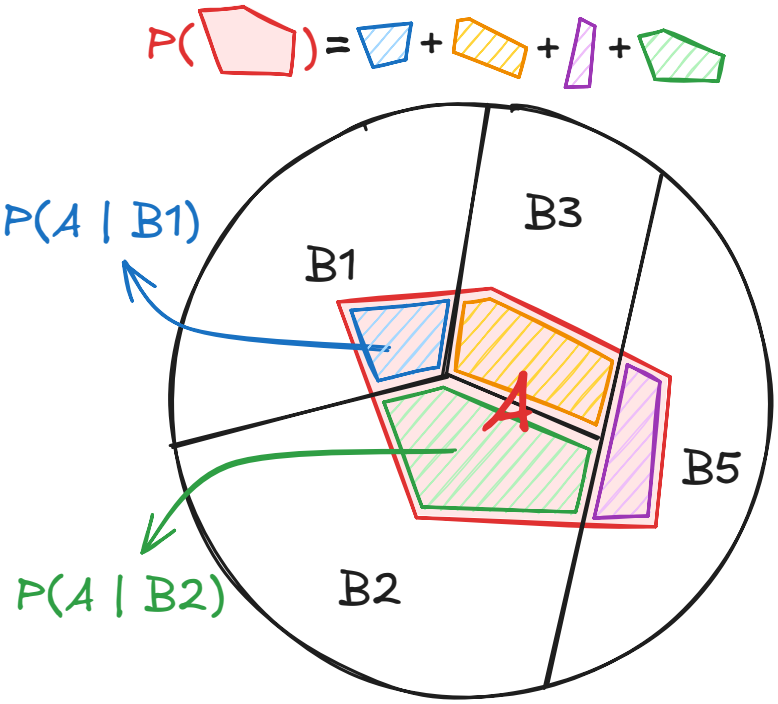
1. 定义: $P(A \mid B) = \dfrac{P(AB)}{P(B)}$.
2. 乘法公式: $P(AB) = P(A)P(B \mid A)$, 归纳可得

$$P(A_1A_2 \ldots A_n) = P(A_1)P(A_2 \mid A_1) \ldots P(A_n \mid A_1A_2 \ldots A_{n-1})$$

3.2 全概率公式

若 $\{B_n\}$ 是样本空间的一个完备事件群 (无交, 并为 Ω), 则有

$$P(A) = \sum_{i=1}^{n} P(A \mid B_i)P(B_i)$$

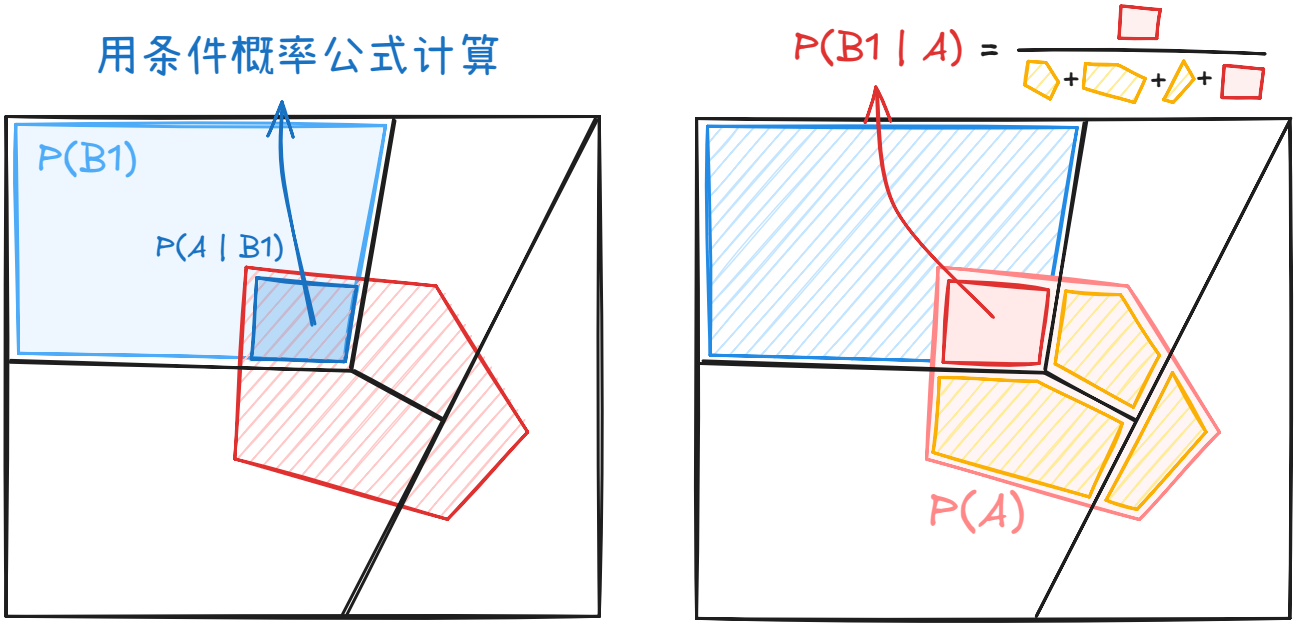


直观理解, $P(\text{red}) = \sum P(\text{色々})$.

3.3 Bayes 公式

若 $\{B_n\}$ 是样本空间的一个完备事件群 (无交, 并为 Ω), 则有

$$P(B_i \mid A) = \frac{P(B_i A)}{P(A)} = \frac{P(A \mid B_i)P(B_i)}{\sum_{j=1}^{n} P(A \mid B_j)P(B_j)}$$



直观理解, 我们已知小蓝方块占大蓝方块的比例. 于是先用左边的图计算出每个小方块的面积, 再用右边的图计算出 A 条件下小红方块占大红方块的面积比例.

3.4 独立性

定义: 两个事件满足 $P(AB)=P(A)P(B)$, 则称 A,B 相互独立. 更一般地, 若

$$P\left(\bigcap_{i=1}^{n}A_i\right)=\prod_{i=1}^{n}P(A_i)$$

则称这些事件相互独立. 等价命题有:

- $P(B\mid A)=P(B)$;
- A 或 $\bar{A}$ 与 B 或 $\bar{B}$ 相互独立. 更一般地, 令 $\tilde{A}_i=A_i$ 或 $\bar{A}_i$, 有

$$P\left(\bigcap_{i=1}^{n}\tilde{A}_i\right)=\prod_{i=1}^{n}P(\tilde{A}_i)$$

---

4 随机变量

4.1 离散型随机变量

4.1.1 概率质量函数 (PMF)

如果随机变量 X 只能取有限多个或可数多个值, 那么称 X 为离散型随机变量. 设 $\{x_k\}$ 为 X 所有取值的集合, 则称

$$P(X=x_k)=p_k$$

为离散型随机变量 X 的分布律或概率质量函数.

4.2 连续型随机变量

4.2.1 累积分布函数 (CDF)

设 X 为一随机变量, $x\in\mathbb{R}$, 称

$$F(x)=P(X\leqslant x)$$

为随机变量 X 的 (累积) 分布函数.

4.2.2 概率密度函数 (PDF)

若存在可积的非负函数 $f(x)\geqslant 0$, 使得

$$\forall x \in \mathbb{R}, \quad F(x) = \int_{-\infty}^{x} f(t)\,\mathrm{d}t$$

则称 X 为连续型随机变量, $f(x)$ 称为分布函数或概率密度函数, 记为 $X \sim f(x)$.

4.2.3 概率密度函数的性质

- 恒为非负;
- $\int_{-\infty}^{+\infty} f(x)\,\mathrm{d}x = 1$;
- 对任意可测集 $A \subseteq \mathbb{R}$, 有

$$P(X \in A) = \int_{A} f(x)\,\mathrm{d}x$$

- 若 $f(x)$ 在 x_0 连续, 则有 $F'(x_0) = f(x_0)$;
- $\forall x \in \mathbb{R}$, $P(X = x) = 0$.

4.2.4 分布的复合

设 $X \sim f(x)$, 随机变量 $Y = g(X)$, 则有

$$F_Y(y) = \int_{g(x) \leqslant y} f(x)\,\mathrm{d}x$$

若在 $\mathbb{R}$ 严格单调且反函数可导时, 设 $X = h(Y)$, 则有

$$f_Y(y) = f(h)|h'|$$

若 $g(x)$ 在各个区间 I_i 上分别严格单调, 则有

$$f_Y(y) = \sum_i f(h)\left|h'\right| \cdot \mathbf{1}_{I_i}(y)$$

---

5 一维随机变量的数字特征

5.1 期望

5.1.1 定义

离散型随机变量 X 的期望

$$E(X) = \sum_{k \geqslant 1} x_k p_k \leqslant \infty$$

连续型随机变量 $X \sim f(x)$ 的期望

$$E(X) = \int_{\mathbb{R}} x f(x) \, \mathrm{d}x \leqslant \infty$$

5.1.2 期望的性质

- 线性性;
- 相互独立随机变量: 可乘性;
- 条件期望: 称下式为给定 $X = x$ 时随机变量 Y 的条件期望

$$E(Y \mid X = x) = \int_{\mathbb{R}} y f_{Y|X}(y \mid x) \, \mathrm{d}y$$

- 全期望公式: $E(Y \mid X)$ 是关于 X 的随机变量, 且满足

$$E(E(Y \mid X)) = E(Y)$$

5.1.3 期望的复合

类比 $E(x) = \int \boxed{x} f(x) \, \mathrm{d}x$, 若我们要求一个变量 $y = y(x)$ 的期望, 有:

$$E(Y) = \int \boxed{y(x)} f(x) \, \mathrm{d}x$$

离散则类比 $E(x) = \sum k \cdot P(x = k)$ 有:

$$E(Y) = \sum y(k) \cdot P(x = k)$$

5.2 位置统计量

5.2.1 中位数

随机变量 $X \sim F(x)$, 中位数 m 满足:

$$P(X \geqslant m) = 1 - F(m - 0) \geqslant \frac{1}{2}, \quad P(X \leqslant m) = F(m) \geqslant \frac{1}{2}$$

可以不唯一.

5.2.2 众数

使得随机变量 X 的概率质量函数 (PMF, X 离散时) 或概率密度函数 (PDF, X 连续时) 达到最大的常数 m_d 称为众数.

可以不唯一.

5.2.3 分位数

- p 分位数: 设 $p \in (0,1)$, 随机变量 X 的 p 分位数 Q_p 定义为

$$P(X \leqslant Q_p) \geqslant p, \quad P(X \geqslant Q_p) \geqslant 1-p$$

- 内四分位距: $\mathrm{IQR} = Q_{0.75} - Q_{0.25}$.

5.3 矩

5.3.1 定义

随机变量 X, 满足 $E(|X|^k) < \infty$, 则称 $E(X-c)^k$ 为 X 关于 c 的 k 阶矩; 称 $\alpha_k = E(X^k)$ 为 X 的 k 阶原点矩; 称 $\mu_k = E((X-E(X))^k)$ 为 X 的 k 阶中心矩.

5.3.2 矩母函数

随机变量 X 的矩母函数 (MGF) 定义为

$$M_X(s) = E(e^{sX})$$

矩母函数唯一决定随机变量分布. 其具有许多优秀的性质:

- 考虑拉普拉斯变换: $M_X(-s) = \mathcal{L}\{f_X\}(s)$;
- 其在 $t=0$ 处的 n 阶导数即为 X 的 n 阶原点矩;
- 独立随机变量相加的分布, 其矩母函数相乘.

5.4 方差和标准差

5.4.1 定义

随机变量 X 关于其均值 μ 的二阶中心矩称为 X 的方差

$$\sigma^2 = \mathrm{Var}(X) = E[(X-\mu)^2]$$

方差的算术平方根称为 X 的标准差

$$\sigma = \sqrt{\mathrm{Var}(X)}$$

对于连续变量而言

$$\mathrm{Var}(X) = \int_{-\infty}^{+\infty} (x-\mu)^2 f(x)\,\mathrm{d}x$$

5.4.2 性质

- 平方的均值减均值的平方: $\mathrm{Var}(X) = E(X^2) - E(X)^2$;
- 伸缩: $\mathrm{Var}(cX) = c^2\,\mathrm{Var}(X)$;
- 平移不变: $\mathrm{Var}(X+d) = \mathrm{Var}(X)$;
- 可加性: 独立随机变量, 和的方差等于方差的和;
- $\mathrm{Var}(X) \leqslant E[(X-c)^2]$, 当且仅当 $c = E(X)$ 时取等.

5.5 不等式们

- 马尔可夫不等式: 若随机变量 $X \geqslant 0$, 则

$$\forall \varepsilon > 0, \quad P(X \geqslant \varepsilon) \leqslant \frac{E(X)}{\varepsilon}$$

- 切比雪夫不等式: 若方差和均值均存在, 则

$$P(|x-\mu| > k\sigma) \leq \frac{1}{k^2}$$

---

6 常见离散分布

6.1 伯努利分布

伯努利分布 (Bernoulli distribution) 描述单次二元试验的结果. 其 PMF 为

$$\mathbb{P}(X = x; p) = p^x (1-p)^{1-x}, \quad x \in \{0,1\},\ p \in (0,1)$$

记作 $X \sim \mathrm{Bernoulli}(p)$. 支撑集为 $\{0,1\}$.

6.1.1 均值与方差

其 $\mathbb{E}[X] = p$, $\mathrm{Var}(X) = p(1-p)$.

6.2 二项分布

二项分布 (Binomial distribution) 描述 n 次独立伯努利试验中成功次数的分布. 其 PMF 为

$$\mathbb{P}(X=k;n,p)=\binom{n}{k}p^k(1-p)^{n-k},\quad k=0,1,\dots,n$$

记作 $X\sim\text{Binomial}(n,p)$. 支撑集为 $\{0,1,\dots,n\}$.

6.2.1 均值与方差

其 $\mathbb{E}[X]=np$, $\text{Var}(X)=np(1-p)$.

6.2.2 性质

- 再生性: 若 $X\sim\text{Bin}(n_1,p)$,$Y\sim\text{Bin}(n_2,p)$ 且 $X\perp Y$, 则 $X+Y\sim\text{Bin}(n_1+n_2,p)$;
- Poisson 逼近定理:
  设一族随机变量 $X_n\sim B(n,p_n)$, 若当 $n\to\infty$ 时, $np_n\to\lambda>0$, 则有

  $$\lim_{n\to\infty}P(X_n=k)=\frac{\lambda^k}{k!}e^{-\lambda}$$

  实际应用中, $n\geqslant 30$ 且 $np_n\leqslant 5$ 时即可应用.

6.3 几何分布

几何分布 (Geometric distribution) 描述首次成功所需的试验次数(或失败次数). 常见定义如下:

- 版本一 (首次成功所需总试验次数):

  $$\mathbb{P}(X=k;p)=(1-p)^{k-1}p,\quad k=1,2,\dots$$

- 版本二 (首次成功前的失败次数):

  $$\mathbb{P}(X=k;p)=(1-p)^{k}p,\quad k=0,1,2,\dots$$

  记作 $X\sim\text{Geom}(p)$. 支撑集依定义分别为 $\{1,2,\dots\}$ 或 $\{0,1,2,\dots\}$.

6.3.1 均值与方差

- 版本一: $\mathbb{E}[X]=\dfrac{1}{p}$, $\text{Var}(X)=\dfrac{1-p}{p^2}$;
- 版本二: $\mathbb{E}[X]=\dfrac{1-p}{p}$, $\text{Var}(X)=\dfrac{1-p}{p^2}$.

6.3.2 性质

- 唯一具有无记忆性的离散分布:

$$\mathbb{P}(X > s+t \mid X > s) = \mathbb{P}(X > t), \quad s,t \in \mathbb{N}_0.$$

6.4 负二项分布

负二项分布 (Negative binomial distribution) 描述第 r 次成功出现时的失败次数. 其 PMF 为

$$\mathbb{P}(X = k; r, p) = \binom{k+r-1}{r-1} p^r (1-p)^k, \quad k = 0, 1, 2, \dots$$

记作 $X \sim \mathrm{NB}(r, p)$, 其中 $r \in \mathbb{N}^+$, $p \in (0,1)$. 支撑集为 $\mathbb{N}_0$.

6.4.1 均值与方差

其 $\mathbb{E}[X] = \dfrac{r(1-p)}{p}$, $\mathrm{Var}(X) = \dfrac{r(1-p)}{p^2}$.

6.4.2 性质

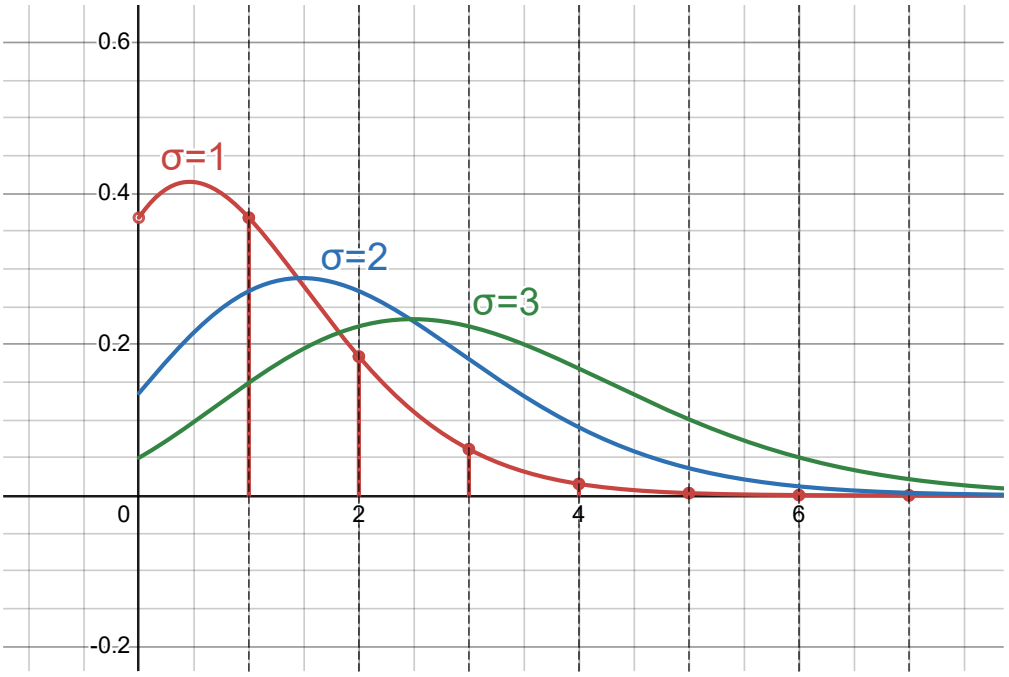
- 当 $r = 1$ 时退化为几何分布 (版本二);
- 可视为 r 个独立同分布的几何分布 (版本二) 之和, 所以方差为其 r 倍.

6.5 泊松分布

泊松分布 (Poisson Distribution) 常用于描述单位时间内稀有事件的发生次数. 其 PMF 为

$$\mathbb{P}(X = k; \lambda) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \mathbb{N}_0,\ \lambda > 0$$

记作 $X \sim \mathrm{Pois}(\lambda)$. 支撑集为 $\mathbb{N}_0 = \{0, 1, 2, \dots\}$.



6.5.1 均值与方差

其 $\mathbb{E}[X] = \lambda$, $\mathrm{Var}(X) = \lambda$.

6.5.2 性质

- 再生性: 若 $X \sim \mathrm{Pois}(\lambda_1)$, $Y \sim \mathrm{Pois}(\lambda_2)$ 且 $X \perp Y$, 则 $X + Y \sim \mathrm{Pois}(\lambda_1 + \lambda_2)$.
- 泊松近似: 当 $n \to \infty$, $p \to 0$, $np \to \lambda$ 时, $B(n, p) \xrightarrow{d} \mathrm{Pois}(\lambda)$.

6.5.3 与泊松过程的联系

若事件按强度 λ 的泊松过程[2]发生，则单位时间内的事件数服从 $\mathrm{Pois}(\lambda)$; 事件间隔时间服从 $\mathrm{Exp}(\lambda)$.

6.6 超几何分布

超几何分布 (Hypergeometric distribution) 描述无放回抽样中成功次数的分布. 其 PMF 为

$$\mathbb{P}(X = k; N, K, n) = \frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}}, \quad \max(0, n+K-N) \le k \le \min(n, K)$$

记作 $X \sim \mathrm{Hypergeometric}(N, K, n)$, 其中 N 为总体大小, K 为总体中成功数, n 为抽样数. 支撑集为整数区间 $[\max(0, n+K-N), \min(n, K)]$.

6.6.1 均值与方差

其 $\mathbb{E}[X] = n \cdot \dfrac{K}{N}$, $\mathrm{Var}(X) = n \cdot \dfrac{K}{N} \cdot \left(1 - \dfrac{K}{N}\right) \cdot \dfrac{N-n}{N-1}$.

6.6.2 性质

- 当 $N \to \infty$ 且 $K/N \to p$ 固定时, 超几何分布趋近于 $\mathrm{Bin}(n, p)$;
- 方差中的因子 $\dfrac{N-n}{N-1}$ 称为有限总体校正因子 (finite population correction).

6.7 离散均匀分布

离散均匀分布 (Discrete uniform distribution) 在有限整数集上等概率取值. 设支撑集为 $\{a, a+1, \ldots, b\}$, 其中 $a, b \in \mathbb{Z}$, $a \le b$. 其 PMF 为

$$\mathbb{P}(X = k) = \frac{1}{b - a + 1}, \quad k = a, a+1, \ldots, b$$

记作 $X \sim \mathrm{Uniform}\{a, \ldots, b\}$.

6.7.1 均值与方差

其 $\mathbb{E}[X] = \dfrac{a+b}{2}$, $\mathrm{Var}(X) = \dfrac{(b-a+1)^2 - 1}{12}$.

6.7.2 性质

- 是对称分布;
- 若 $a = 1, b = n$, 常用于模拟公平骰子.

---

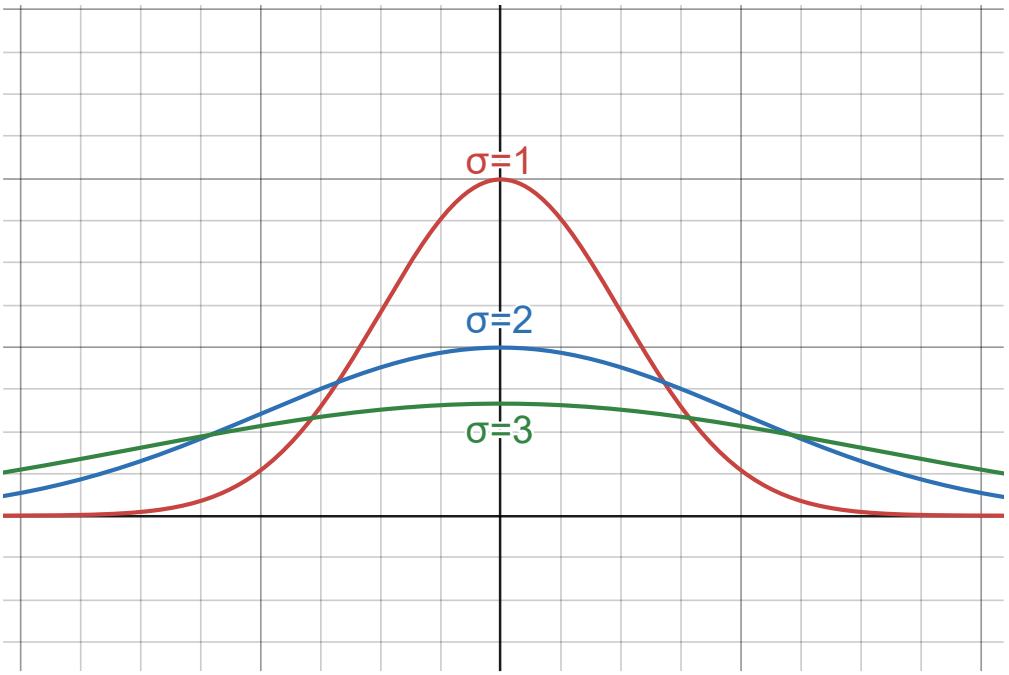
7 常见连续分布

7.1 正态分布

正态分布也称 Gauss 分布, 为统计学最常见的分布之一. 其 PDF 为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}$$

记作 $X \sim \mathcal{N}(\mu, \sigma^2)$. 支撑集为 $\mathbb{R}$.



7.1.1 均值与方差

其 $\mathbb{E}[X] = \mu$, $\mathrm{Var}(X) = \sigma^2$.

7.1.2 性质

- 线性变换: $aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$.
- 再生性: $\sum_{i=1}^{n} X_i \sim \mathcal{N}\left(\sum \mu_i, \sum \sigma_i^2\right)$.

7.2 均匀分布

均匀分布 (Uniform Distribution) 在区间 $[a, b]$ 上具有恒定密度. 其 PDF 为

$$f(x; a, b) = \frac{1}{b - a}, \quad x \in [a, b]$$

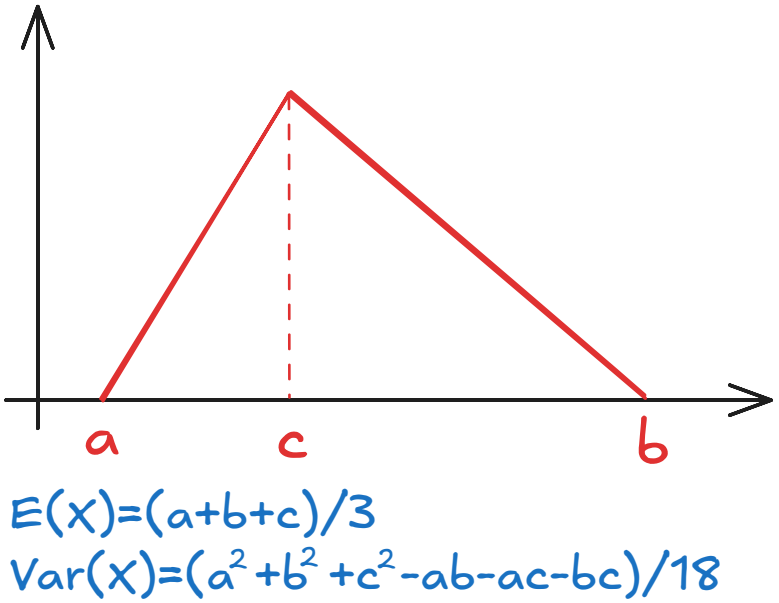
记作 $X \sim \mathcal{U}(a, b)$. 支撑集为 $[a, b]$.

7.2.1 均值与方差

其 $\mathbb{E}[X] = \dfrac{a + b}{2}$, $\mathrm{Var}(X) = \dfrac{(b - a)^2}{12}$.

7.2.2 相加

- 区间长度相等的两个均匀分布相加, 是三角分布;



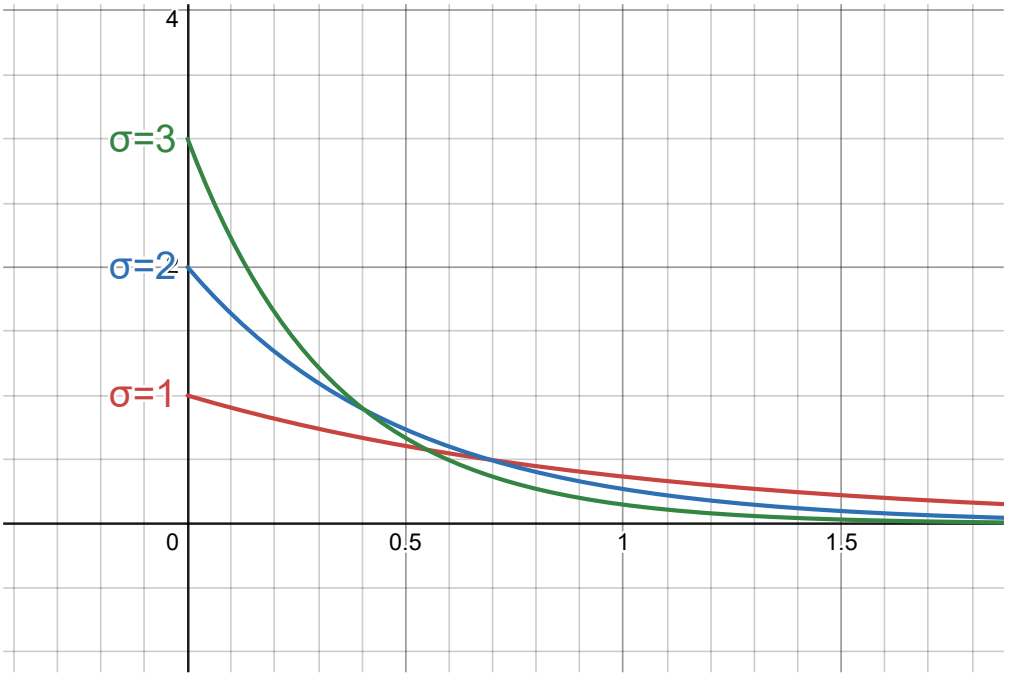
- 若两个均匀分布分别为 $U_1(a, a+d), U_2(b, b+d)$, 则相加为 $\text{Triangle}(a+b, a+b+2d, a+b+d)$.
- 多个均匀分布相加, 是 Irwin-Hall 分布.

7.3 指数分布

指数分布 (Exponential Distribution) 常用于描述等待时间. 其 PDF 为

$$f(x;\lambda) = \lambda e^{-\lambda x}, \quad x \geq 0,\ \lambda > 0$$

记作 $X \sim \text{Exp}(\lambda)$. 支撑集为 $[0, \infty)$.



7.3.1 均值与方差

其 $\mathbb{E}[X] = \dfrac{1}{\lambda}$, $\text{Var}(X) = \dfrac{1}{\lambda^2}$.

7.3.2 性质

无记忆性: $P(X > s+t \mid X > s) = P(X > t)$.

7.3.3 和与差

- 和 $\sum X_i$ 满足下面的伽马分布.
- 差 $D = X - Y$ 满足 Laplace 分布:

$$f_D(d) = \frac{\lambda}{2} e^{-\lambda |d|}, \quad d \in \mathbb{R}$$

7.4 伽马分布

伽马分布 (Gamma Distribution) 是指数分布与卡方分布的推广. 其 PDF 为

$$f(x;\alpha,\beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x>0,\ \alpha>0,\ \beta>0$$

记作 $X \sim \mathrm{Gamma}(\alpha,\beta)$.[3] 支撑集为 $(0,\infty)$.

7.4.1 均值与方差

其 $\mathbb{E}[X] = \dfrac{\alpha}{\beta}$, $\mathrm{Var}(X) = \dfrac{\alpha}{\beta^2}$.

7.4.2 性质

- $k \cdot \mathrm{Gamma}(\alpha,\beta) \to \mathrm{Gamma}(\alpha, \dfrac{\beta}{k})$;
- n 个伽马相加: $\sum^n \mathrm{Gamma}(\alpha,\beta) \to \mathrm{Gamma}(n\alpha,\beta)$

7.4.3 特例

- $\alpha = 1$: 退化为 $\mathrm{Exp}(\beta)$;
- $\alpha = \dfrac{k}{2},\ \beta = \dfrac{1}{2}$: 得卡方分布 χ^2_k.
- 注意 $\alpha = 0$ 的时候不是 Laplace 分布.

7.5 柯西分布

柯西分布用于构造正态分布的比.

$$f(x;x_0,\gamma)=\frac{1}{\pi\gamma}\cdot\frac{1}{1+\left(\dfrac{x-x_0}{\gamma}\right)^2},\quad x\in\mathbb{R}$$

记作 $X\sim\text{Cauchy}(x_0,\gamma)$, 其中 $x_0\in\mathbb{R}$ 为位置参数, $\gamma>0$ 为尺度参数. 支撑集为 $\mathbb{R}$.

上面这个有点难记, 标准柯西分布取 $x_0=0,\gamma=1$, 即

$$f(x)=\frac{1}{\pi(1+x^2)}.$$

7.5.1 均值与方差

均值与方差均不存在, 中位数与众数均为 x_0.

7.5.2 性质

再生性: $\text{Cauchy}(x_1,\gamma_1)+\text{Cauchy}(x_2,\gamma_2)=\text{Cauchy}(x_1+x_2,\gamma_1+\gamma_2)$.

7.5.3 构造方式

- 若 $\Theta\sim\text{Uniform}(-\pi/2,\pi/2)$，则 $X=\tan\Theta\sim\text{Cauchy}(0,1)$;
- 若 $X,Y\overset{\text{ind.}}{\sim}\mathcal{N}(0,1)$，则 $Z=X/Y\sim\text{Cauchy}(0,1)$.

---

8 多维随机变量

8.1 joint



8.1.1 联合分布函数 (joint CDF)

设 (X,Y) 是二维随机变量, 称二元函数

$$F(x,y)=P(X\leqslant x,Y\leqslant y)$$

为 (X,Y) 的联合分布函数.

8.1.2 联合概率密度函数 (joint PDF)

设 $(X,Y)\sim F(x,y)$, 若存在可积的非负函数 $f(x,y)\geqslant 0$, 使得

$$\forall (x,y)\in\mathbb{R}^2,\quad F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}f(u,v)\,du\,dv$$

则称 (X,Y) 为二维连续型随机变量, $f(x,y)$ 称为联合概率密度函数.

8.2 边缘分布

8.2.1 边缘概率密度函数 (marginal PDF)

设 $(X,Y)\sim F(x,y)$, 其中 $X\sim F_X(x)$, $Y\sim F_Y(y)$, 则称 $F_X(x)$ 和 $F_Y(y)$ 为 (X,Y) 或 F 的边缘分布 (marginal distribution). 对应的 $f_X(x)$ 和 $f_Y(y)$ 称为 $f(x,y)$ 的边缘概率密度函数 (marginal PDF). 且有

$$F_X(x)=\lim_{y\to\infty}F(x,y),\quad f_X(x)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}y$$

8.2.2 条件概率密度函数 (conditional PDF)

给定 $Y=y$ 条件下随机变量 X 的条件概率密度函数为

$$f_{X|Y}(x\mid y)=\frac{f(x,y)}{f_Y(y)}$$

8.2.3 推广: n 维情况

对于一组随机变量 $(X_1,X_2,\ldots,X_n)\sim F$, 记 $U=\{X_1,X_2,\ldots,X_k\}$, $V=\{X_{k+1},X_{k+2},\ldots,X_n\}$, 则 U 的边缘分布为

$$F_U(u)=F(x_1,x_2,\ldots,x_k,\infty,\infty,\ldots,\infty)$$

边缘密度函数为

$$f_U(u)=\int_{\mathbb{R}^{n-k}}f(u,v)\,dv$$

n 维随机变量的边缘分布函数有 (2^n-2) 个. 给定 $V=v$ 条件下, 随机变量 U 的条件概率密度函数为

$$f_{U|V}(u\mid v)=\frac{f(u,v)}{f_V(v)}$$

8.2.4 随机变量独立性

若联合密度函数可以"分离", 即

$$\forall (x,y)\in\mathbb{R}^2,\quad F(x,y)=F_X(x)F_Y(y)$$

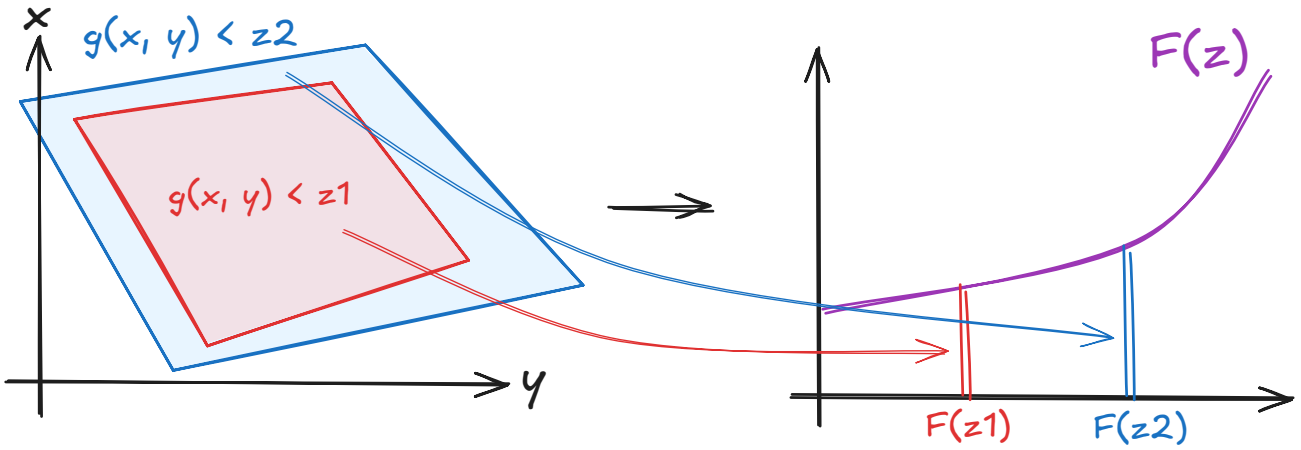
则称随机变量 X,Y 相互独立. 可以推广到 n 维情况.

8.3 随机向量函数的分布

8.3.1 一维情况

$Z=g(X,Y)$, 则有

$$F_Z(z)=\iint_{g(x,y)\leqslant z} f(x,y)\,\mathrm{d}x\,\mathrm{d}y$$



8.3.2 二维情况

$(Z_1,Z_2)=(g_1(X,Y),g_2(X,Y))$, 则有

$$F_Z(z_1,z_2)=\iint_{\substack{g_1(x,y)\leqslant z_1\\ g_2(x,y)\leqslant z_2}} f(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

若 g_1,g_2 是一一映射, $(x,y)=(h_1(z_1,z_2),h_2(z_1,z_2))$, 则有

$$f_Z(z_1,z_2)=f(h_1(z_1,z_2),h_2(z_1,z_2))\left|\frac{\partial(h_1,h_2)}{\partial(z_1,z_2)}\right|$$

实际上可以类比一元公式 $f_Y=f(h)|h'|$.

$$f_Z(z_1)=f(h_1(z_1))|\frac{\partial h_1}{\partial z_1}|$$

8.3.3 多维情况

可以根据二维情况推广 .

8.4 二维正态分布

参考 [https://www.desmos.com/3d/w9uo2ucazl?lang=zh-CN].

8.4.1 表达式

设随机向量 $(X,Y)^\top$ 服从二维正态分布, 记作

$$(X,Y)^\top \sim \mathcal{N}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

其中:

- 均值向量 $\boldsymbol{\mu} = (\mu_X, \mu_Y)^\top \in \mathbb{R}^2$
- 协方差矩阵:

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix}$$

  其中 $\sigma_X > 0, \sigma_Y > 0$, 且相关系数 $\rho \in (-1, 1)$, 退化情形 $|\rho| = 1$ 时密度不存在.

8.4.2 参数化

其联合概率密度函数 (joint PDF) 为:

$$f_{X,Y}(x,y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)} Q(x,y) \right)$$

其中二次型:

$$Q(x,y) = \frac{(x-\mu_X)^2}{\sigma_X^2} - 2\rho\frac{(x-\mu_X)(y-\mu_Y)}{\sigma_X\sigma_Y} + \frac{(y-\mu_Y)^2}{\sigma_Y^2}$$

$$= \begin{bmatrix} x-\mu_X \\ y-\mu_Y \end{bmatrix} \boldsymbol{\Sigma}^{-1} \begin{bmatrix} x-\mu_X & y-\mu_Y \end{bmatrix}$$

8.4.3 边缘分布

给定 $X = a$, Y 的条件分布为正态分布:

$$Y \mid X = a \sim \mathcal{N}\left(\mu_Y + \rho\frac{\sigma_Y}{\sigma_X}(a-\mu_X),\ \sigma_Y^2(1-\rho^2) \right)$$

特别地, 对标准二元正态 (standard bivariate normal):

- $\mu_X = \mu_Y = 0, \sigma_X = \sigma_Y = 1$;
- $Y \mid X = a \sim \mathcal{N}(\rho a, 1 - \rho^2)$.
  我们可以理解为, 非标准的二元正态只不过是做了均值的平移和拉伸.

由此可得:

- 条件期望 $\mathbb{E}[Y \mid X = a] = \rho a$, 是 a 的线性函数.
- 条件方差 $\mathrm{Var}(Y \mid X) = 1 - \rho^2$ 与 X 无关 (同方差性).

8.4.4 半正态分布

标准二维正态分布的 $Z = |X - Y|$ 符合参数为 $\sigma^2 = 2(1 - \rho)$ 的半正态分布, 这个性质可以用于计算最大值和最小值的分布.

设 $Z \sim \mathcal{N}(0, \sigma^2)$, 定义 $Y = |Z|$, 则 Y 服从半正态分布, 记作 $Y \sim \mathrm{HalfNormal}(\sigma)$.

- PDF: $f_Y(y) = \dfrac{1}{\sigma}\sqrt{\dfrac{2}{\pi}} \exp\left(-\dfrac{y^2}{2\sigma^2}\right)$.
- 期望: $\mathbb{E}[Y] = \sigma\sqrt{\dfrac{2}{\pi}}$.
- 二阶矩: $\mathbb{E}[Y^2] = \sigma^2$.
- 方差: $\mathrm{Var}(Y) = \sigma^2\left(1 - \dfrac{2}{\pi}\right)$.
- 中位数 $\approx 0.6745\sigma$; 均值 $\approx 0.7979\sigma$, 分布右偏.

---

9 多维随机变量数字特征

9.1 协方差

9.1.1 定义

随机变量 X 或 Y 均平方可积且平方均值有限, 则随机变量 X, Y 的协方差为

$$\mathrm{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

立得

$$\mathrm{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

上式可类比 $\operatorname{Var}(X)=E(XX)-E(X)E(X)$.

9.1.2 协方差的性质

- $\operatorname{Cov}(X,Y)=\operatorname{Cov}(Y,X)$;
- 协方差矩阵:

$$\operatorname{Cov}(aX+bY,cX+dY)=\begin{pmatrix}a & b\end{pmatrix}\begin{pmatrix}\operatorname{Var}(X) & \operatorname{Cov}(X,Y)\\ \operatorname{Cov}(X,Y) & \operatorname{Var}(Y)\end{pmatrix}\begin{pmatrix}c\\ d\end{pmatrix}$$

- 随机变量的 Cauchy–Schwarz 公式, 等价于相关系数小于等于 1:

$$|\operatorname{Cov}(X,Y)|\leqslant\sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)}$$

9.2 相关系数

9.2.1 定义

随机变量 X,Y 协方差存在, 定义其相关系数为

$$\rho_{X,Y}=\frac{\operatorname{Cov}(X,Y)}{\sqrt{\operatorname{Var}(X)}\sqrt{\operatorname{Var}(Y)}}=\frac{\mu_X\mu_Y-\mu_{XY}}{\sigma_X\sigma_Y}$$

9.2.2 与独立性的关系

- 若随机变量相互独立, 则随机变量间的相关系数为 0;
- 反之不必成立, 但在随机变量服从二元正态分布时二者等价.
- 独立 $\Rightarrow$ 不相关, 不相关 $\nRightarrow$ 独立.[4]

9.2.3 性质

如下五个命题等价:

1. X 与 Y 不相关;
2. $\rho_{X,Y}=0$;
3. $\operatorname{Cov}(X,Y)=0$;
4. $E(XY)=E(X)E(Y)$;
5. $\operatorname{Var}(X+Y)=\operatorname{Var}(X)+\operatorname{Var}(Y)$.

9.3 不独立变量的方差

当很多变量之间不独立时, $X = a_1X_1 + \cdots + a_nX_n$ 的方差为:

$$\operatorname{Var}(X) = \sum a_i^2 \operatorname{Var}(X_i) + 2\sum_{i<j} a_i a_j \operatorname{Cov}(X_i, X_j)$$

或用相关系数:

$$\operatorname{Var}(X) = \sum a_i^2\sigma_i^2 + 2\sum_{i<j} a_i a_j \rho_{ij}\sigma_i\sigma_j$$

9.4 熵

离散型随机变量的熵定义为

$$H(X) = -\sum_{k=1}^{\infty} p_k \log_2(p_k)$$

连续型随机变量的熵 (微分熵) 定义为

$$H(X) = -\int_{-\infty}^{+\infty} f_X(x)\ln f_X(x)\,\mathrm{d}x$$

---

10 极限定理

对于 i.i.d. 随机变量 $X_1, X_2, \ldots, X_n$, 记 $S_n = \sum_{i=1}^{n} X_i$, 则有:

10.1.1 Khinchin 弱大数定律

$$\forall \varepsilon > 0, \quad \lim_{n\to\infty} P\left(\left|\frac{S_n}{n} - \mu\right| \geqslant \varepsilon\right) = 0$$

样本均值依概率收敛于总体均值.

10.1.2 Lindeberg –Levy 中心极限定理 (CLT)

$$\frac{\sqrt{n}(S_n/n - \mu)}{\sigma} \xrightarrow{d} N(0,1)$$

收敛到方差 ($\operatorname{Var}(\bar{X}) = \dfrac{\sigma^2}{n}$) 和均值相同的正态分布.

10.1.3 De Moivre–Laplace 定理

$X_i \sim B(1,p)$,

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0,1)$$

就是 CLT 的推论.

数理统计

1 基本概念

1.1 样本

总体中按一定方式抽取的 n 个个体被称为是样本量为 n 的一个样本, 记为 $X = (X_1, X_2, \ldots, X_n)$.

放回抽样得到的样本是简单随机样本, 简单随机样本中 $X_1, X_2, \ldots, X_n$ 满足 i.i.d., 简单样本的联合分布函数为 $\prod_{i=1}^n F(x_i)$, 联合概率密度函数 (若存在) 为 $\prod_{i=1}^n f(x_i)$.

1.2 常见统计量

完全由样本 X 决定 (不含有参数) 的量被称为统计量, 常见统计量有:

- 样本均值: $\bar{X} = \dfrac{1}{n}\sum_{i=1}^n X_i$;
- 样本方差: $S^2 = \dfrac{1}{n-1}\sum_{i=1}^n (X_i - \bar{X})^2$, 其中 $S = \sqrt{S^2}$ 被称为样本标准差;
- 样本 k 阶原点矩: $a_k = \dfrac{1}{n}\sum_{i=1}^n X_i^k$;
- 样本 k 阶中心矩: $m_k = \dfrac{1}{n}\sum_{i=1}^n (X_i - \bar{X})^k$;
- 样本偏度系数 (Skewness): $S \equiv \hat{\beta}_1 = \dfrac{m_3}{m_2^{3/2}}$;
- 样本超额 (Excess) 峰度系数: $K_e = K - 3$, 用于使得正态分布的峰度系数为 0.
- 样本峰度系数 (Skewness): $K \equiv \hat{\beta}_2 = \dfrac{m_4}{m_2^2}$;
- 样本相关系数:

$$\rho_n = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\left(\sum_{i=1}^n (X_i - \bar{X})^2\right)\left(\sum_{i=1}^n (Y_i - \bar{Y})^2\right)}}$$

- 次序统计量: 把样本 X 从小到大排列为

$$X_{(1)} \leqslant X_{(2)} \leqslant \cdots \leqslant X_{(n)}$$

- 样本中位数:

$$m_n = \begin{cases} X_{(\frac{n+1}{2})}, & \text{when } n \text{ is odd;} \\ \dfrac{1}{2}(X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}), & \text{when } n \text{ is even.} \end{cases}$$

- 经验分布函数 $F_n(x) = \dfrac{N(x)}{n}$, 其中 $N(x)$ 是 X 中的样本数据小于等于 x 的个数.

---

2 常见分布

2.1 χ^2 分布

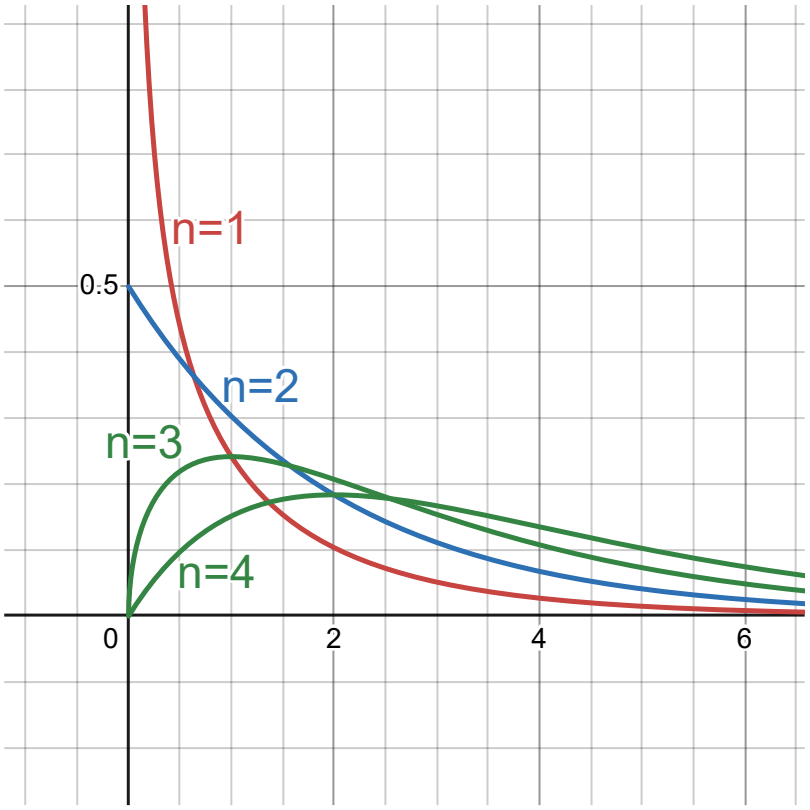
2.1.1 定义

X 是来自标准正态分布总体的一个简单随机样本, 称

$$X := \sum_{i=1}^n X_i^2$$

服从自由度为 n 的 χ^2 分布, 记为 $X \sim \chi_n^2$. 显然有 χ_n^2 分布的概率密度函数

$$k_n(x) = \frac{1}{\Gamma(\dfrac{n}{2}) 2^{\frac{n}{2}}} e^{-\frac{1}{2}x} x^{\frac{n}{2}-1} \mathbf{1}_{(0,+\infty)}(x)$$



2.1.2 χ^2 分布的性质

- 若 $X \sim \chi_n^2$, 则有 $E(X) = n$, $\mathrm{Var}(X) = 2n$;
- 若 $X \sim \chi_m^2$, $Y \sim \chi_n^2$ 且 X, Y 相互独立, 则 $X + Y \sim \chi_{m+n}^2$;
- $\chi_n^2 = \mathrm{Gamma}(\frac{n}{2}, \frac{1}{2})$.

2.2 t 分布

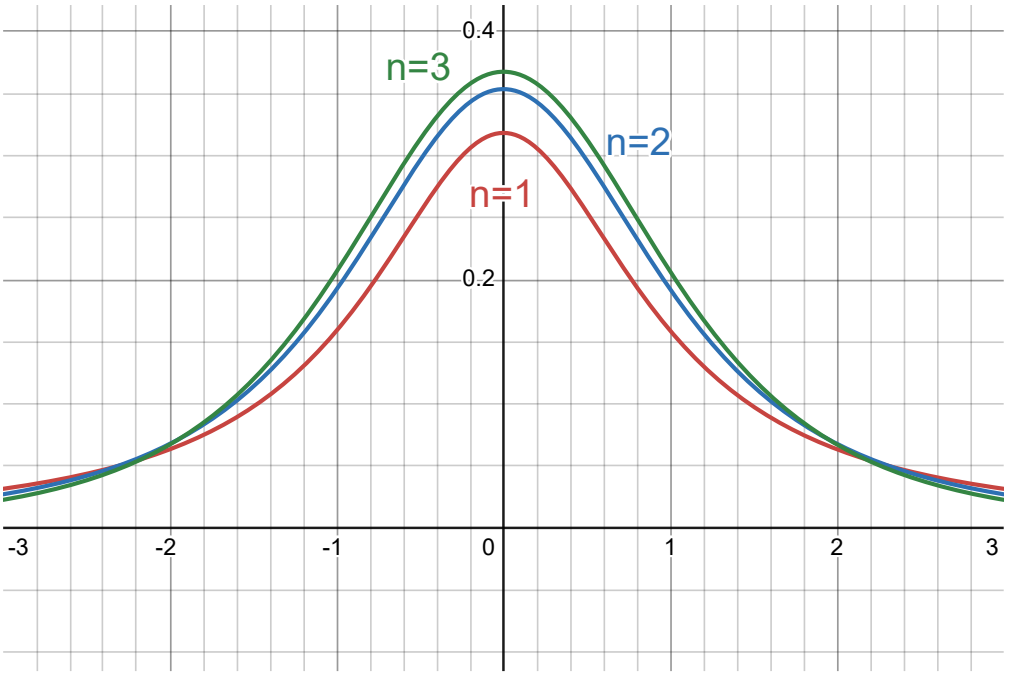
2.2.1 性质

设 $X \sim N(0,1)$, $Y \sim \chi_n^2$, 且 X, Y 相互独立, 称

$$T = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t 分布, 记为 $T \sim t_n$. 显然有 t_n 分布的概率密度函数

$$f_n(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\,\Gamma(\frac{n}{2})}\left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad t \in \mathbb{R}$$



2.2.2 t 分布的性质

- 当 $n=1$ 时, t 分布就是 Cauchy 分布. 此时方差不存在;
- 若 $T\sim t_n$, 当 $n\geqslant 2$ 时, $E(T)=0$; 当 $n\geqslant 3$ 时 $\mathrm{Var}(T)=\dfrac{n}{n-2}$;
- $\lim_{n\to\infty} f_n(t)=\phi(t)$, 其中 $\phi(t)$ 是标准正态分布的概率密度函数.

2.3 F 分布

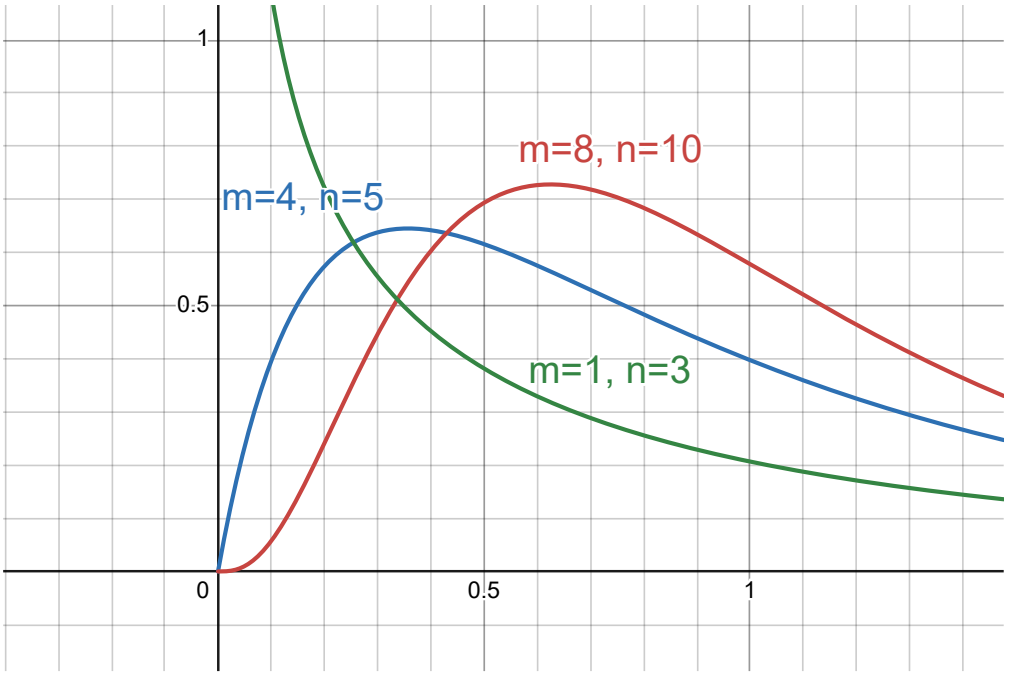
2.3.1 定义

设 $X\sim\chi^2_m, Y\sim\chi^2_n$, 且 X,Y 相互独立, 称

$$F=\frac{X/m}{Y/n}$$

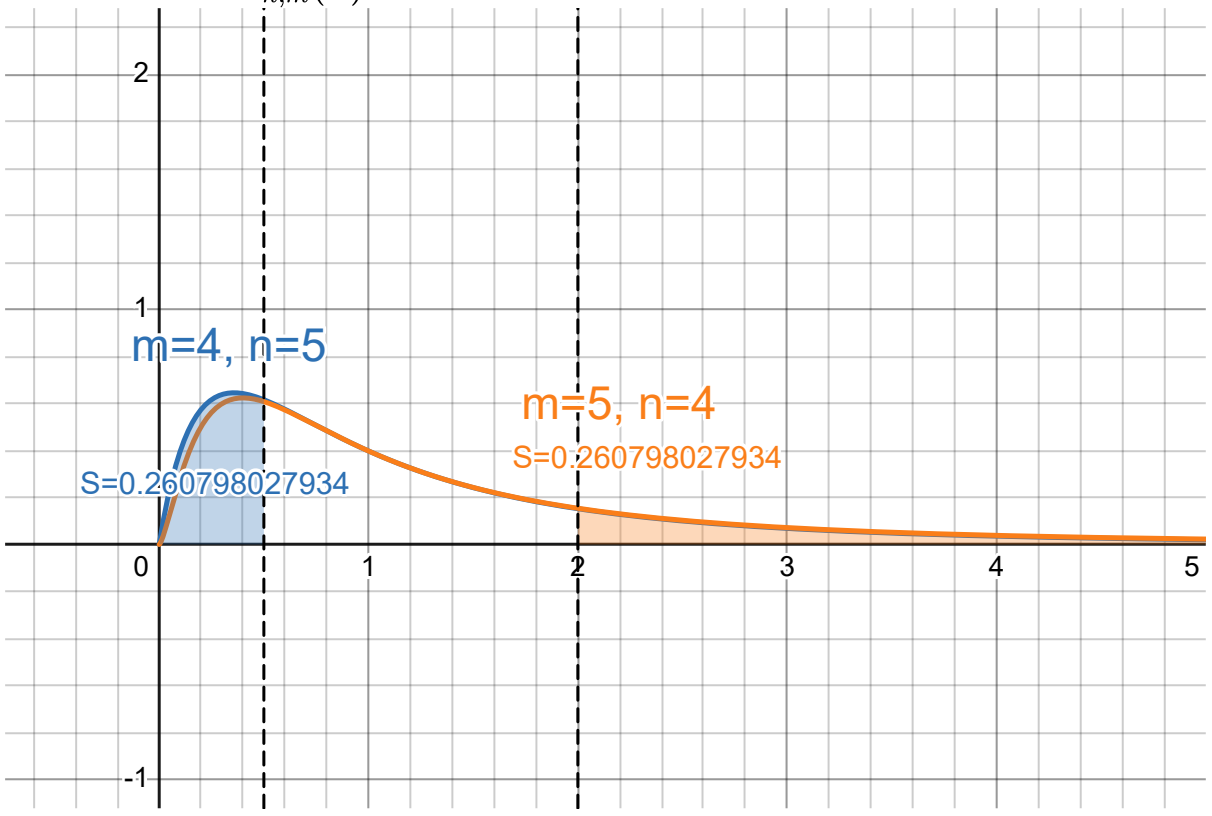
服从自由度为 m,n 的 F 分布, 记为 $F\sim F_{m,n}$. 显然[5]有 $F_{m,n}$ 分布的概率密度函数

$$f_{m,n}(x)=m^{\frac{m}{2}}n^{\frac{n}{2}}\frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})}x^{\frac{m}{2}-1}(mx+n)^{-\frac{m+n}{2}}\mathbf{1}_{(0,+\infty)}(x)$$



2.3.2 F 分布的性质

- 若 $Z \sim F_{m,n}$, 则 $\dfrac{1}{Z} \sim F_{n,m}$;
- 若 $T \sim t_n$, 则 $T^2 \sim F_{1,n}$;
- $F_{m,n}(1-\alpha) = \dfrac{1}{F_{n,m}(\alpha)}$.



3 样本分布

3.1 正态分布

3.1.1 基本性质

设简单样本 X 均来自 $N(\mu,\sigma^2)$ 的总体, 则有

- 再生性:

$$T=\sum_{i=1}^{n}c_iX_i\sim N\left(\mu\sum_{i=1}^{n}c_i,\ \sigma^2\sum_{i=1}^{n}c_i^2\right)$$

- 样本均值 $\bar{X}\sim N(\mu,\dfrac{\sigma^2}{n})$;
- 样本标准误 $\dfrac{(n-1)S^2}{\sigma^2}\sim\chi^2_{n-1}$, 注意这里由于均值未知, 自由度 -1;
- $\bar{X}$ 与 S^2 相互独立, 故 $\dfrac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t_{n-1}$.

3.1.2 推论

若 m 样本量 X 和 n 样本量样本 Y 所有变量相互独立, 且分别来自总体 $N(\mu_1,\sigma_1^2)$, $N(\mu_2,\sigma_2^2)$, 则有:

1. 满足标准差相同[6]的时候有:

$$T=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_T}\sqrt{\frac{mn}{m+n}}\sim t_{m+n-2}$$

2. 方差之比:

$$F=\frac{S_X^2}{S_Y^2}\cdot\frac{\sigma_2^2}{\sigma_1^2}\sim F_{m-1,n-1}$$

   其中 S_T 称为合并标准差, 满足

$$S_T^2=\frac{(m-1)S_X^2+(n-1)S_Y^2}{m+n-2}$$

3.2 指数分布

若 X 来自参数为 λ 的指数分布, 则有

$$2\lambda n\bar{X} = 2\lambda \sum_{i=1}^{n} X_i \sim \chi^2_{2n}$$

使用 Gamma 分布可以推导. 如何记住前面的系数呢? 考虑 $E(\bar{X}) = \dfrac{1}{\lambda}$, 而 $E(\chi^2_{2n}) = 2n$, 所以要乘上一个 $2n\lambda$ 的系数.

---

4 参数点估计

4.1 参数点估计 (Point Estimation)

给定一个参数化概率模型 $\{F_\theta : \theta \in \Theta\}$, 其中:

- F_θ 是总体 X 的分布函数;
- θ 是一个未知参数, 取值是 $\Theta \subseteq \mathbb{R}^d$;
- 我们观测到一组 i.i.d. 样本 $X_1 \dots X_n$, 它们都服从 F_θ.
  点估计的目标就是在不事先知道 θ 的前提下，基于样本 $X_1, \dots, X_n$ 构造 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$. 统计量不能依赖任何未知量, 只可依赖观测数据, 并希望 $\hat{\theta}$ 在某种意义下*接近*真值 θ.

4.2 估计量的评价标准

- 无偏性: 若 $\mathbb{E}_\theta[\hat{\theta}] = \theta$ 对所有 $\theta \in \Theta$ 成立.
- 一致性: 若 $\hat{\theta}_n \xrightarrow{P} \theta$ (依概率收敛) 当 $n \to \infty$.
- 有效性: 在无偏估计类中, 若 $\mathrm{Var}_\theta(\hat{\theta})$ 达到 Cramér–Rao 下界, 则称其为有效估计量.

4.3 矩估计法 (Method of Moments, MoM)

矩估计由 Karl Pearson 于 1894 年提出, 其基本思想是用样本矩匹配总体矩, 从而解出参数.

4.3.1 原点矩 (Raw Moment)

总体 j 阶原点矩通常记为:

$$m_j / \mu'_j = \mathbb{E}[X^j]$$

4.3.2 中心矩 (Central Moment)

总体 j 阶中心矩记为:

$$\mu_j = \mathbb{E}\big[(X - \mathbb{E}[X])^j\big]$$

特别地:

- $\mu_1 = 0$,
- $\mu_2 = \mathrm{Var}(X) = \sigma^2$,
- μ_3 用于定义偏度 (skewness),
- μ_4 用于定义峰度 (kurtosis).

4.3.3 核心思想

矩估计的基本思路是: 用样本矩去匹配总体矩, 从而反解出未知参数. *例:*

- 假设总体分布由 k 个未知参数 $\theta = (\theta_1, \dots, \theta_k)^\top$ 决定.
- 用样本计算出对应的前 k 阶原点矩, 并令它们分别等于理论矩 μ_j;
- 得到一个关于 θ 的方程组;
- 解这个方程组;
- 所得到的解 $\hat{\theta}_{\mathrm{MoM}}$ 就是参数的矩估计量.

4.3.4 矩估计的局限

矩估计要求所用矩存在. 例如, 对 Cauchy 分布:

$$f(x; x_0, \gamma) = \frac{1}{\pi\gamma\left[1 + \left(\dfrac{x - x_0}{\gamma}\right)^2\right]}, \quad x \in \mathbb{R}$$

其均值与高阶矩均不存在 (积分发散), 故矩估计完全失效. 此时必须使用其他方法 (如最大似然估计, 但是 MLE 也无解析解, 所以只能残念地用中位数估计).

4.4 最大似然估计 (Maximum Likelihood Estimation, MLE)

4.4.1 似然函数

设总体 X 的分布属于参数化族 $\{P_\theta : \theta \in \Theta\}$, 给定 i.i.d. 样本 $X_1, \dots, X_n \sim P_\theta$, 似然函数 (likelihood function) 定义为:

$$L(\theta;\mathbf{x}) := \prod_{i=1}^{n} f(x_i;\theta)$$

视作 θ 的函数. 对数似然函数 (log-likelihood function) 为

$$\ell(\theta;\mathbf{x}) := \log L(\theta;\mathbf{x}) = \sum_{i=1}^{n} \log f(x_i;\theta)$$

对数似然函数用的极其之多.

4.4.2 最大似然估计

若统计量 $\hat{\theta}_{\mathrm{MLE}}$ 满足

$$L(\hat{\theta}_{\mathrm{MLE}};\mathbf{X}) = \sup_{\theta\in\Theta} L(\theta;\mathbf{X}) \quad \text{a.s.}$$

则称其为 θ 的最大似然估计量 (Maximum Likelihood Estimator). 由于 log 单调, 等价于最大化 $\ell(\theta;\mathbf{x})$.

4.4.3 求解

在内点 $\theta_0 \in \Theta^\circ$ 且满足正则性条件下, MLE 满足似然方程:

$$\frac{\partial \ell(\theta;\mathbf{x})}{\partial \theta_j} = 0, \quad j = 1,\dots,d$$

若 MLE 位于参数空间边界 (如 $U(0,\theta)$ 的 $\hat{\theta} = X_{(n)}$), 则似然方程不适用, 必须直接分析似然函数的极值.

4.4.4 渐近性质

1. 一致性: $\hat{\theta}_{\mathrm{MLE}} \xrightarrow{P} \theta$.
2. 渐近正态性:

   $$\sqrt{n}(\hat{\theta}_{\mathrm{MLE}} - \theta) \xrightarrow{d} \mathcal{N}(0, I(\theta)^{-1})$$

   其中 $I(\theta)$ 为 Fisher 信息矩阵.
3. 渐近有效性: 渐近方差达到 Cramér–Rao 下界.

4.5 Cramér–Rao 不等式

4.5.1 CRLB

设 $\hat{\theta} = \hat{\theta}(X_1, \ldots, X_n)$ 是 θ 的无偏估计量 (unbiased estimator), 即 $\mathbb{E}_\theta[\hat{\theta}] = \theta$ 对所有 $\theta \in \Theta$ 成立, 且 $\mathrm{Var}_\theta(\hat{\theta}) < \infty$. 则在上述正则性条件下,

$$\mathrm{Var}_\theta(\hat{\theta}) \geq \frac{1}{I_n(\theta)} = \frac{1}{nI_1(\theta)}$$

该下界称为 Cramér–Rao 下界 (Cramér–Rao Lower Bound, CRLB).

4.5.2 有效性

若某个无偏估计量 $\hat{\theta}$ 满足 $\mathrm{Var}_\theta(\hat{\theta}) = 1/I_n(\theta)$ 对所有 θ 成立, 则称其为有效估计量 (efficient estimator).

---

5 估计的评价

5.1 偏差

$\hat{\theta}(X)$ 是 $g(\theta)$ 的一个估计量, 则偏差为

$$E_\theta(\hat{\theta}(X)) - g(\theta)$$

偏差为 0 的估计为无偏估计. 样本数据的加权和是总体期望的无偏估计; 样本方差是总体方差的无偏估计, 二阶中心矩估计不是.

5.2 最小方差无偏估计 (MVUE)

5.2.1 误差

均方误差:

$$\mathrm{MSE}_\theta(\hat{\theta}) = E_\theta((\hat{\theta}(X) - \theta)^2)$$

平均绝对误差:

$$\mathrm{MAE}_\theta(\hat{\theta}) = E_\theta(|\hat{\theta}(X) - \theta|)$$

无偏估计下 $\mathrm{MSE}_\theta(\hat{\theta}) = \mathrm{Var}_\theta(\hat{\theta})$.

5.2.2 最有效估计

若 $\mathrm{Var}_\theta(\hat{\theta}_1) \leqslant \mathrm{Var}_\theta(\hat{\theta}_2)$, 且存在 θ 使小于号成立, 则称 $\hat{\theta}_1$ 更有效. 对于任意无偏估计 $\hat{\theta}$ 满足 $\mathrm{Var}_\theta(\hat{\theta}^*) \leqslant \mathrm{Var}_\theta(\hat{\theta})$ 的 $\hat{\theta}^*$ 被称为最小方差无偏估计, 即在均方误差标准下最有效的估计.

- $\bar{X}$ 是 μ 的 MVUE (其他的权重都没有它有效);
- 当 μ 已知时, $\dfrac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2$ 是 σ^2 的一个 MVUE.

5.3 相合性

若点估计 $\hat{\theta}$ 在样本量 $n \to \infty$ 时依概率趋近于 θ, 则称 $\hat{\theta}$ 是 θ 的一个 (弱) 相合估计. 相合性是对一个估计量的最基本要求. 若一个估计量没有相合性, 则无论样本量多大也不能把未知参数估计到任意精度, 这种估计是不可取的.

5.4 渐近正态性

若点估计 $\hat{\theta}$ 在样本量 $n \to \infty$ 时

$$\frac{\hat{\theta}(X)-\theta}{\sqrt{\mathrm{Var}_\theta(\hat{\theta}(X))}} \xrightarrow{d} N(0,1)$$

则称 $\hat{\theta}$ 有渐近正态性.

---

6 区间估计

6.1 置信区间

参数 θ, 统计量 $\hat{\theta}_1, \hat{\theta}_2$, 则参数 θ 的置信系数为 $1-\alpha$ 的区间是 $[\hat{\theta}_1, \hat{\theta}_2]$ 可表示为

$$P(\hat{\theta}_1 \leqslant \theta \leqslant \hat{\theta}_2) = 1-\alpha$$

α 是一个小的正数, 通常取 0.01, 0.05, 0.1.

或者我们写成

$$\text{点估计} \pm \text{分位数} \times \text{标准误(SE)}$$

6.2 枢轴变量法

可以分为以下步骤:

1. 找一个 θ 的良好点估计 $T(X)$, 一般为最大似然估计 (例如 $T(X)=\bar{X}$ 估计 $\theta=\mu$);
2. 构造枢轴 $S(T,U,\theta)$ 使得 S 分布已知 (设其概率分布函数为 F), 其中 U 为统计量 (例如构造 $\dfrac{\sqrt{n}(\bar{X}-\mu)}{\sigma}\sim N(0,1)$);
3. 枢轴变量区应满足 $w_{1-\alpha}\leqslant S\leqslant w_\alpha\Rightarrow\hat{\theta}_1\leqslant\theta\leqslant\hat{\theta}_2$, 其中 w_α 为 F 的上 α 分位数 (满足 $F(w_\alpha)=1-\alpha$).

6.3 枢轴变量法的应用

6.3.1 正态总体均值 μ 的置信区间

设置信区间为 $\bar{x}\pm d$, 则误差界限 d 为 (用 $\hat{\sigma}$ 估计时总体不必为正态分布)

$$d=\begin{cases}\dfrac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}, & \text{when } \sigma^2 \text{ is known;}\\[2ex] \dfrac{s}{\sqrt{n}}t_{n-1}\left(\alpha/2\right), & \text{when } \sigma^2 \text{ is unknown;}\\[2ex] \dfrac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}, & \text{when } n>30 \text{ and } \sigma^2 \text{ is unknown.}\end{cases}$$

6.3.2 正态总体方差 σ^2 的置信区间

若总体均值已知, 自由度为 n, 即

$$\sigma^2\in\left[\frac{\sum_{i=1}^n(x_i-\mu)^2}{\chi_n^2\left(\alpha/2\right)},\frac{\sum_{i=1}^n(x_i-\mu)^2}{\chi_n^2\left(1-\alpha/2\right)}\right]$$

若总体均值未知, 可考虑枢轴估计 $\dfrac{(n-1)S^2}{\sigma^2}\sim\chi_{n-1}^2$, 此时

$$\sigma^2\in\left[\frac{(n-1)S^2}{\chi_{n-1}^2\left(\alpha/2\right)},\frac{(n-1)S^2}{\chi_{n-1}^2\left(1-\alpha/2\right)}\right]$$

6.3.3 均值差的置信区间

设置信区间为 $\bar{y}-\bar{x}\pm d$, 则误差界限 d 为

$$d=\begin{cases}\sqrt{\dfrac{\sigma_1^2}{m}+\dfrac{\sigma_2^2}{n}}\cdot u_{\alpha/2}, & \text{when } \sigma_1^2,\sigma_2^2 \text{ are known;}\\[2ex] \sqrt{\dfrac{m+n}{mn}}S_T\cdot t_{m+n-2}\left(\alpha/2\right), & \text{when } \sigma_1^2,\sigma_2^2 \text{ are unknown.}\end{cases}$$

6.3.4 方差比的置信区间

考虑枢轴估计 $\dfrac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}\sim F_{m-1,n-1}$

$$\frac{\sigma_1^2}{\sigma_2^2}\in\left[\frac{s_1^2}{s_2^2}F_{m-1,n-1}\left(1-\alpha/2\right),\frac{s_1^2}{s_2^2}F_{m-1,n-1}\left(\alpha/2\right)\right]$$

注意利用性质 $F_{a,b}(\alpha)=\dfrac{1}{F_{b,a}(1-\alpha)}$. 有的时候试卷不会给你这些信息.

6.3.5 比例 p 的区间估计

事件 A 在每次试验中发生概率为 p, 若在 n 次试验中发生了 y_n 次, 则 p 的 $1-\alpha$ 置信区间 (Wilson 区间) 为

$$p\in\frac{\hat{p}+\delta}{1+2\delta}\pm\frac{u_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})}+\delta/2}{\sqrt{n}(1+2\delta)}$$

其中 $\hat{p}=\dfrac{y_n}{n},\delta=\dfrac{u_{\alpha/2}^2}{n}$.
一般来说估计 p 置信区间需要 $np>5,n(1-p)>5$. 在实际中我们可以忽略 δ, 即 Wald 区间

$$p\in\hat{p}\pm\boxed{u_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}}$$

可以计算:

- 置信区间宽度 $w=2u_{\alpha/2}\sqrt{\dfrac{\hat{p}(1-\hat{p})}{n}}$.
- 要求的样本量

$$n=\frac{4u_{\alpha/2}^2\cdot\hat{p}(1-\hat{p})}{w^2}$$

例: 正态总体均值 μ 的置信上限在 σ^2 已知时可以写为 $\bar{x}+\dfrac{\sigma}{\sqrt{n}}u_\alpha$.

6.4 自助法

6.4.1 基本自助置信区间

在总体中抽取样本 $\{x_k\}$, 从样本中有放回地抽取一组样本量同样为 n 的样本 $\{x_k^*\}$, 称为一个自助样本. 基于自助样本计算统计量 $\hat{\theta}$ 的值, 称为 $\hat{\theta}$ 的一个自助版本. 重复 B 次, 在 B 个自助版本中记 $\alpha/2$ 分位数为 a, $1-\alpha/2$ 分位数为 b, 则 θ 的 $1-\alpha$ 基本自助区间为

$$[2\hat{\theta}-b,2\hat{\theta}-a]$$

6.4.2 自助 t 置信区间

记自助版本 $\hat{\theta}^*$ 的标准差估计为

$$\widehat{\mathrm{se}}_B(\hat{\theta})=\sqrt{\frac{1}{B-1}\sum_{i=1}^{B}(\hat{\theta}_i^*-\bar{\hat{\theta}}^*)^2}$$

第 b 个重复下的 "T 类型" 为

$$t^{(b)}=\frac{\hat{\theta}_b^*-\hat{\theta}}{\widehat{\mathrm{se}}_B(\hat{\theta}_b^*)}$$

其中 $\widehat{\mathrm{se}}_B(\hat{\theta}_b^*)$ 是对第 b 个自助样本再采用自助法生成 R 个自助版本得到的 $\hat{\theta}_b^*$ 的标准差.

记 "T 类型" 中的 $\alpha/2$ 分位数为 t_a, $1-\alpha/2$ 分位数为 t_b, 则最终得到的 $1-\alpha$ 自助 t 置信区间为

$$[\hat{\theta}-t_b\widehat{\mathrm{se}}_B(\hat{\theta}),\hat{\theta}-t_a\widehat{\mathrm{se}}_B(\hat{\theta})]$$

6.5 置信限

"参数 θ 的置信系数为 $1-\alpha$ 的置信上限是 $\overline{\theta}$" 可表示为

$$P(\overline{\theta}\geqslant\theta)=1-\alpha$$

"参数 θ 的置信系数为 $1-\alpha$ 的置信下限是 $\underline{\theta}$" 可表示为

$$P(\underline{\theta}\leqslant\theta)=1-\alpha$$

7 假设检验

7.1 假设

7.1.1 基本概念

1. 原假设 H_0, 备择假设 H_1.
2. 常见的假设: 两点假设, 双边假设, 单边假设.
3. 检验一个假设时用到的统计量称为假设统计量.
   - 使假设得到接受的样本集合 (样本落在区域) 为接受域;
   - 被拒绝的区域为拒绝域;
   - 接受域和拒绝域的边界为临界值.
4. 功效函数: 根据样本 X 所做的一个检验 Ψ, 对应的功效函数为

$$\beta_\Psi(\theta) = P_\theta(\text{在检验 } \Psi \text{ 下假设 } H_0 \text{ 被否定的概率})$$

5. 根据功效函数可以得到检验 Ψ 的检验水平 α:

$$\beta_\Psi(\theta) \leqslant \alpha, \quad \forall \theta \in H_0$$

7.1.2 设立假设的原则

设立原假设和备择假设的两条原则

- 把已有的经过考验的结论或事实作为原假设 H_0;
- 把希望得到的结论放在备择假设 H_1, 希望能通过拒绝原假设得到希望得到的结论.

7.2 两类错误

- H_0 成立, 但检验 Ψ 拒绝了 H_0, 则称为第一类错误, 即 "弃真错误", 发生的概率为 $\alpha_{1\Psi}(\theta) = \beta_\Psi(\theta),\ \theta \in H_0$;
- H_0 不成立, 但检验 Ψ 接受了 H_0, 则称为第二类错误, 即 "存伪错误", 发生的概率为 $\alpha_{2\Psi}(\theta) = 1 - \beta_\Psi(\theta),\ \theta \in H_1$.
- 可以把第一类错误和第二类错误理解为 "冤枉好人" 和 "放过坏人".

7.3 显著性检验

仅考虑第一类错误的检验称为显著性检验，显著性检验的一般方法如下：

1. 求出未知参数 θ 的一个较优的点估计 $\hat{\theta}$；
2. 寻找一个检验统计量 $T(\hat{\theta}, U, \theta_0)$，使得 $\theta = \theta_0$ 时 T 的分布已知；
3. 根据备择假设的实际意义寻找 T 的拒绝域；
4. 计算在原假设成立的条件下犯第一类错误的概率小于等于给定的显著性水平 α，得到一个临界值（T 在 $\theta = \theta_0$ 的 α 分位数），确定拒绝域；
5. 根据已有数据计算检验统计量是否在拒绝域中；
6. 根据具体问题解释是否能拒绝原假设.

7.4 单个正态总体均值的检验

设定假设：

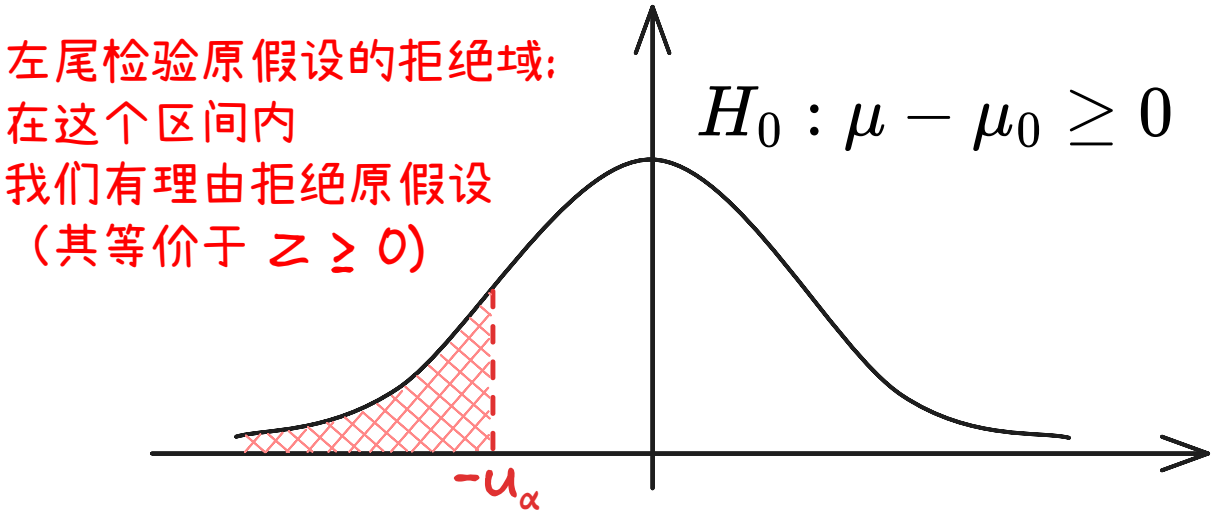
1. $H_0 : \mu \geqslant \mu_0 \leftrightarrow H_1 : \mu < \mu_0$，左尾检验，检测某量是否降低；
2. $H_0' : \mu \leqslant \mu_0 \leftrightarrow H_1' : \mu > \mu_0$，右尾检验，检验某量是否升高；
3. $H_0'' : \mu = \mu_0 \leftrightarrow H_1'' : \mu \neq \mu_0$，双尾检验，检验某量是否存在偏差

7.4.1 当 σ^2 已知

$$Z = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} \sim N(0, 1)$$

水平为 α 的检验为：

- Ψ：当 $Z < -u_\alpha$ 时拒绝 H_0，否则不能拒绝 H_0；
- Ψ'：当 $Z > u_\alpha$ 时拒绝 H_0'，否则不能拒绝 H_0'；
- Ψ''：当 $|Z| > u_{\alpha/2}$ 时拒绝 H_0''，否则不能拒绝 H_0''.



7.4.2 当 σ^2 未知

$$T=\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}\sim t_{n-1}$$

水平为 α 的检验为:

- Φ: 当 $T<-t_{n-1}(\alpha)$ 时拒绝 H_0, 否则不能拒绝 H_0;
- Φ': 当 $T>t_{n-1}(\alpha)$ 时拒绝 H_0', 否则不能拒绝 H_0';
- Φ'': 当 $|T|>t_{n-1}\left(\alpha/2\right)$ 时拒绝 H_0'', 否则不能拒绝 H_0''.

> ⚠ **Warning**
>
> 下面不再写出详细的假设和检验, 只构造枢轴.

7.5 成组比较两个正态总体均值差

记 δ 为均值差.

7.5.1 当 σ^2 已知

$$Z=\frac{\bar{X}-\bar{Y}-\delta}{\sigma\sqrt{\frac{1}{m}+\frac{1}{n}}}\sim N(0,1)$$

7.5.2 当 σ^2 未知

$$T=\frac{\bar{X}-\bar{Y}-\delta}{S_T\sqrt{\frac{1}{m}+\frac{1}{n}}}\sim t_{m+n-2}$$

S_T 为合并标准差, 定义见上.

7.6 成对比较两个正态总体均值差

构造新的样本 $Z_i=X_i-Y_i$, 并对 Z 的均值做假设检验.

7.7 正态总体方差的检验

$$\chi^2=\frac{(n-1)S^2}{\sigma_0^2}\sim\chi^2_{n-1}$$

7.8 两个正态分布总体方差比的检验

$$F=\frac{S_1^2}{bS_2^2}\sim F_{m-1,n-1}$$

7.9 比例 p 的检验

设 X 是 $B(1,p)$ 的一个样本, 关于 p 设定假设 $p\ \Delta\ p_0$, 其中 Δ 表示单边或者双边:

考虑统计量 $X=\sum X_i\sim B(n,p)$, 由分布函数 $F_p(C)=\sum_{i=0}^{C}\binom{n}{i}p^i(1-p)^{n-i}$. 常见的对应的三个检验方法为:

- ψ: 当 $X>C$ 时拒绝 H_0, 否则不能拒绝 H_0. 其中 C 由下式决定:

$$F_{p_0}(C)\geqslant 1-\alpha;$$

- ψ': 当 $X<C'$ 时拒绝 H_0', 否则不能拒绝 H_0'. 其中 C' 由下式决定:

$$F_{p_0}(C'-1)\leqslant \alpha;$$

- ψ'': 当 $X<C_1$ 或 $X>C_2$ 时拒绝 H_0'', 否则不能拒绝 H_0''. 其中 C_1,C_2 由下式决定:

$$F_{p_0}(C_1-1)\leqslant \alpha/2,\quad F_{p_0}(C_2)\geqslant 1-\alpha/2.$$

例: 以检验 ψ 为例, 实际上 C 作为整数不一定能取到, 即 C 满足

$$F_{p_0}(C)<1-\alpha<F_{p_0}(C+1).$$

一种常见的随机化检验是 ψ_0:

- 当 $X\leqslant C$ 时不拒绝 H_0;
- 当 $X>C+1$ 时拒绝 H_0;
- 当 $X=C+1$ 时, 从 $[0,1]$ 中任取一个随机数 u, 若下式成立则拒绝 H_0, 否则不拒绝, 如下图所示:

$$u>\frac{(1-\alpha)-F_{p_0}(C)}{F_{p_0}(C+1)-F_{p_0}(C)}$$



7.10 似然比的检验

考虑假设

$$H_0:\theta\in\Theta_0 \leftrightarrow H_1:\theta\in\Theta_1=\Theta\setminus\Theta_0$$

设样本 X 有联合概率密度函数 $f(x;\theta)$, 称下面统计量为上述假设的似然比:

$$\mathrm{LR(x)}=\frac{\sup_{\theta\in\Theta}f(x;\theta)}{\sup_{\theta\in\Theta_0}f(x;\theta)}$$

而一个似然比的检验 ϕ 可以写为: 当 $\mathrm{LR}(x)>c$ 时拒绝原假设 H_0, 否则不能拒绝 H_0. 其中常数 c 由检验水平决定 (此时可以通过 $\mathrm{LR}(x)$ 的分布确定).

7.11 似然比的极限分布

1. $\Theta\subset\mathbb{R}^d$ 是开集;
2. Θ_0 是 Θ 的一个光滑子流形, 维度为 $d-t$;
   相对于施加了 t 个约束, $\dim\Theta-\dim\Theta_0=t$, 则在原假设 H_0 成立之下, 当样本量 $n\to\infty$ 时有

   $$2\ln\mathrm{LR}(X)\xrightarrow{d}\chi^2_t$$

   例: 正态分布中设 $X_i\sim\mathcal{N}(\mu,\sigma^2)$, σ^2 已知. 检验 $H_0:\mu=\mu_0$ 和 $H_1:\mu\neq\mu_0$.
   可知 $\Theta=\mathbb{R}$, $\dim=1$; $\Theta_0=\{\mu_0\}$, $\dim=0$, 故 $t=1$.
   故似然比:

   $$\mathrm{LR}=\frac{\sup_\mu L(\mu)}{L(\mu_0)}=\exp\left(\frac{n}{2\sigma^2}(\bar{x}-\mu_0)^2\right)$$

   所以:

   $$2\ln\mathrm{LR}=\frac{n}{\sigma^2}(\bar{x}-\mu_0)^2=\left(\frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}}\right)^2\sim\chi^2_1$$

   这与 $Z^2\sim\chi^2_1$ 一致.

7.12 p 值

抽象地定义 p 值为

$$P(\text{得到比当前 }T\text{ 更极端的值}\mid H_0\text{ 成立})$$

对应的检验可以写为 ϕ: 当 p 值 $< \alpha$ 时, 拒绝原假设.

例: 正态总体均值的检验 $H_0 : \mu = 2 \leftrightarrow H_1 : \mu > 2$, 方差 $\sigma^2 = 1$ 已知, 当前样本 X 的均值为 3.5, 考虑检验统计量 $T = \dfrac{\sqrt{n}(\bar{X} - 2)}{1}$, 当前样本下检验统计量为 $t_{\text{obs}} = 3.5$, 故对应的 p 值为

$$P(T \geqslant t_{\text{obs}} \mid H_0) = 1 - \Phi(t_{\text{obs}})$$

其中 H_0 即代表 $\mu = 2$, 我们已代入检验统计量中.

---

8 非参数假设检验

8.1 基础概念

我们通常用卡方检验一组数据的拟合优度.

8.1.1 自由度

定义为 $\text{dof} = n - 1 - \lambda$, 其中 n 为类别的个数, λ 为未知参数的个数.

8.1.2 卡方统计量

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}$$

其中 O_i 是观测频数, E_i 是期望.

8.2 理论分布完全已知 且 有限个取值

总体 X 的值域为 $\{a_1, a_2, \ldots, a_k\}$, 抽取一个样本量为 n 的简单样本, 其中有 n_i 次取 a_i, 则

$$Z = \sum_{i=1}^{k} \left[\frac{(n_i - np_i)^2}{np_i} \right] = \sum_{i=1}^{k} \left(\frac{n_i^2}{np_i} \right) - n$$

- 原假设 H_0: 拟合完全吻合理论分布 $\{p_1, p_2 \ldots p_n\}$;
- 备择假设 H_1: 至少有一个不吻合.

当 $n \to \infty$. Z 的分布趋于自由度为 $(k-1)$ 的 χ^2 分布. 对应的检验写为:

$$\phi:\text{当 } Z>\chi^2_{k-1}(\alpha)\text{ 时拒绝 } H_0,\text{ 否则不能拒绝 } H_0.$$

同时定义数据对理论分布的 "拟合优度":

$$p(Z_0)=P(Z\geqslant Z_0)=1-F_{\chi^2_{k-1}}(Z_0)$$

8.3 理论分布有类型已知 但 含有有限个未知参数

总体 X 的值域为 $\{a_1,a_2,\dots,a_k\}$, 但含有 r 个未知参数 $\theta_1,\theta_2,\dots,\theta_r(r<k-1)$. 抽取一个样本量为 n 的简单样本, 其中有 n_i 次取 a_i, 则

$$Z=\sum_{i=1}^{k}\frac{n_i^2}{n\hat{p}_i}-n$$

原假设 $H_0':P(X=a_i)=p_i(\theta_1,\theta_2,\dots,\theta_r)$ 成立时, 当 $n\to\infty$, Z 的分布趋于自由度为 $(k-r-1)$ 的 χ^2 分布. 对应的检验写为:

$$\phi:\text{当 } Z>\chi^2_{k-r-1}(\alpha)\text{ 时拒绝 } H_0,\text{ 否则不能拒绝 } H_0$$

8.4 列联表的卡方独立性检验

A 有 a 个水平,B 有 b 个水平. 从总体中抽取 n 个独立样本, 记录其 (A,B) 取值, 整理为 $a\times b$ 列联表:

	B_1	$\cdots$	B_b	行和
A_1	n_{11}	$\cdots$	n_{1b}	$n_{1\cdot}=\sum_j n_{1j}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
A_a	n_{a1}	$\cdots$	n_{ab}	$n_{a\cdot}=\sum_j n_{aj}$
列和	$n_{\cdot 1}$	$\cdots$	$n_{\cdot b}$	$n=\sum_{i,j} n_{ij}$

原假设 H_0: A 与 B 独立, 即:

$$\mathbb{P}(A=A_i,\ B=B_j)=\mathbb{P}(A=A_i)\cdot\mathbb{P}(B=B_j),\quad \forall i,j.$$

备择假设 H_1: A 与 B 不独立.

8.4.1 Pearson 卡方统计量

标准形式:

$$\chi^2 = \sum_{i=1}^{a}\sum_{j=1}^{b} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \sum_{i=1}^{a}\sum_{j=1}^{b} \frac{\left(n_{ij} - \dfrac{n_{i\cdot} n_{\cdot j}}{n}\right)^2}{\dfrac{n_{i\cdot} n_{\cdot j}}{n}}$$

等价于:

$$Z = \sum_{i=1}^{a}\sum_{j=1}^{b} \frac{(n n_{ij} - n_{i\cdot} n_{\cdot j})^2}{n\, n_{i\cdot} n_{\cdot j}} = \chi^2.$$

在 H_0 成立且 $n \to \infty$ 时:

$$\chi^2 \xrightarrow{d} \chi^2_{(a-1)(b-1)}.$$

8.4.2 自由度

由于每一行, 每一列消去一个自由度, $\text{dof} = (a-1)(b-1)$.

8.4.3 检验

- 计算观测统计量 χ^2_{obs};
- 查表得临界值 $\chi^2_{(a-1)(b-1)}(\alpha)$;
- 决策:
  - 若 $\chi^2_{\text{obs}} > \chi^2_{(a-1)(b-1)}(\alpha)$, 拒绝 H_0, 认为 A 与 B 相关;
  - 否则, 不拒绝 H_0.

---

1. 指 Qwen, 撰写笔记时的版本号为 Qwen-3Max. ↩
2. 泊松过程 (Poisson process) 是一个计数过程 $\{N(t),\, t \geq 0\}$, 满足 ① $N(0) = 0$; ② 独立增量性 (任意不相交时间区间内的事件数相互独立); ③ 平稳增量性; ④ 每个长度为 t 的区间内事件数服从参数为 λt 的泊松分布 (即 $\mathbb{P}(N(t+s) - N(s) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}$). 等价地, 其事件间隔时间序列 $\{X_n\}$ 是独立同分布的指数随机变量 $X_n \sim \text{Exp}(\lambda)$, 从而第 n 次事件发生时刻 $T_n = \sum_{i=1}^{n} X_i \sim \text{Gamma}(n, \lambda)$. 该过程具有无记忆性, 且在给定 $N(t) = n$ 的条件下, n 个事件的发生时刻在 $[0, t]$ 上的联合分布等同于 n 个独立 $\mathcal{U}(0, t)$ 变量的顺序统计量. ↩
3. 速率参数化 , β 为 rate. ↩
4. 这实际上和 Copula 理论相关. Copula 函数指的是一类把边缘分布 u, v 变成联合分布的函数的函数 ($[0,1]^2 \to [0,1]$). 独立性对应的 Independence Copula ($C(u,v) = uv$) 只是其中一类能保证相关系数为 0 的 Copula 函数. 还有其他诸如 Gauss Copula (

$C_\rho^{\text{Gauss}}(u,v) = \Phi_2\big(\Phi^{-1}(u), \Phi^{-1}(v); \rho\big)$) 等等多种函数, 能够构造一些不独立但相关系数为 0 的联合分布的方法. 选择题里不要写错了哦! ↩

5. 显然在哪? ↩
6. 若方差不同, 则使用 Welch–Satterthwaite 近似. ↩